Guía de actividad

Universidad de La Sabana

A continuación, le presentamos las orientaciones de las actividades de aprendizaje.

Generalidades

Tiempo total previsto para el desarrollo de la actividad: 36 horas

Modalidad de la actividad: grupal

Resultado previsto de aprendizaje (RPA): Identificar, formular y resolver problemas complejos mediante el uso de herramientas analíticas y computacionales.

En esta etapa el diseño se convierte en realidad técnica mediante la implementación de un pipeline distribuido.

Actividad 1. Implementación de pipeline batch o streaming con Spark en entorno cloud.

Introducción al momento:

Desarrollará un flujo funcional que procese datos reales utilizando Spark y almacenamiento distribuido.

Situación problema

La arquitectura diseñada en la Unidad 2 para DATAMARCA S.A. debe ahora convertirse en una solución funcional. El equipo tiene la responsabilidad de implementar un pipeline de procesamiento distribuido que ingeste, transforme y persista un conjunto de datos de transacciones de supermercado en formato estructurado y semiestructurado (registros tabulares CSV y logs JSON de eventos de e-commerce). El sistema debe demostrar capacidad real de procesamiento sobre infraestructura cloud, empleando Apache Spark como motor principal y aprovechando las capacidades del optimizador Catalyst para ejecutar transformaciones complejas sobre DataFrames tipados.El pipeline debe soportar al menos una modalidad de procesamiento batch o streaming y documentar la justificación técnica de esta elección frente a la alternativa no implementada, considerando el modelo unificado de Apache Beam como referente conceptual. Si el equipo opta por el modo streaming, deberá evidenciar el manejo de ventanas temporales y la gestión de datos tardíos (late data). En ambos casos, el pipeline debe incluir validaciones de calidad de datos en la fase de ingestión, transformaciones con SparkSQL o DataFrames, persistencia de resultados en formato Delta Lake o Parquet particionado, y pruebas de rendimiento básicas que reporten tiempo de ejecución y costo estimado. Todo el código debe versionarse en un repositorio Git con estructura de ramas o commits semánticos que evidencie trabajo colaborativo organizado.

Descripción del entregable y pasos de desarrollo:

1. Preparar el dataset de DATAMARCA S.A. (transacciones CSV y logs JSON), definir el esquema de

datos, las reglas de calidad y la estrategia de particionamiento para el almacenamiento distribuido.

2. Implementar la fase de ingestión (batch o streaming) con validaciones básicas de integridad y completitud de datos, justificando la modalidad elegida frente a la alternativa no implementada.

3. Desarrollar las transformaciones con SparkSQL o DataFrames (limpieza, joins entre fuentes, agregaciones de negocio) y persistir los resultados en Delta Lake o Parquet particionado en el almacenamiento cloud.

4. Ejecutar pruebas de rendimiento que reporten tiempo total de ejecución, estimación de costo en el proveedor cloud y comportamiento ante incrementos de volumen, documentando los resultados en el informe técnico.

5. Versionar el código en Git con commits semánticos o estructura de ramas, incluir un archivo README con instrucciones de ejecución reproducible, variables de entorno requeridas y supuestos del entorno cloud.

Recomendaciones:

- Aprovechar el optimizador Catalyst de Spark evitando operaciones que impidan la optimización automática del plan de ejecución, como el uso excesivo de UDFs en Python; preferir operaciones nativas de DataFrames y SparkSQL que el Catalyst puede optimizar mediante predicate pushdown y column pruning.

- Documentar en el README todas las variables de entorno y credenciales requeridas (sin incluir valores sensibles), así como el comando exacto para reproducir la ejecución del pipeline en un entorno limpio; esta documentación es tan importante como el código mismo para demostrar trabajo colaborativo organizado.

- Al generar la evidencia de ejecución, incluir tanto una corrida exitosa completa como los logs de rendimiento con tiempos de cada etapa del pipeline (ingestión, transformación, persistencia), ya que estos datos son la base del análisis de eficiencia requerido en el informe técnico.

Rúbrica de evaluación

Criterios de evaluación	Pts	Indicadores de desempeño								
		Excelente	Pts	Bueno	Pts	Necesita mejorar	Pts	Deficiente	Pts	No cumple con el criterio o no entrega
Funcionalidad del pipeline	2.0	Pipeline completamente funcional y validado con evidencia.	1.75	Funcional con fallas menores.	1.5	Funcional parcial.	1.25	Presenta errores significativos.	0	No funciona.
Eficiencia y optimización	1.5	Implementa buenas prácticas y optimización.	1.25	Buen nivel técnico con oportunidades de mejora.	1.1	Optimización limitada.	0.75	Sin optimización clara.	0	No aplica criterios técnicos.
Control de versiones y documentación	1.0	Uso correcto de Git y documentación reproducible.	0.75	Buen uso con fallas menores.	0.5	Versionamiento limitado.	0.25	Sin estructura clara.	0	No documenta.
Presentación técnica	0.5	Entrega estructurada y clara.	0.25	Entrega adecuada.	0.25	Entrega básica.	0.25	Entrega superficial.	0	0.0 pts. No entrega.
Total		5.0		4.0		3.5		2.5		0.0